Machine Learning for the Humanities

I dati e le parole

Come trasformare testi in numeri?

Lezione 2 · 5 novembre 2026 · Tor Vergata



Un computer conta

La domanda guida

Come trasformare un testo in numeri?

Testo guida: Le avventure di Pinocchio (1883)

Tokenizzare
dividere un testo in parole

Contare
frequenze con un ciclo, un dizionario e Counter

Tabelle e CSV
costruire un DataFrame e salvarlo

Caratteristiche
descrivere un testo con un vettore di numeri

Albero di decisione
addestrarlo e leggerne le regole

Tokenizzare: dal testo alle parole

`c` `era` `una` `volta` `un` `pezzo` `di` `legno`

in Python: `re.findall(r"\w+", testo.lower())`

41.562

token
parole totali in Pinocchio

6080

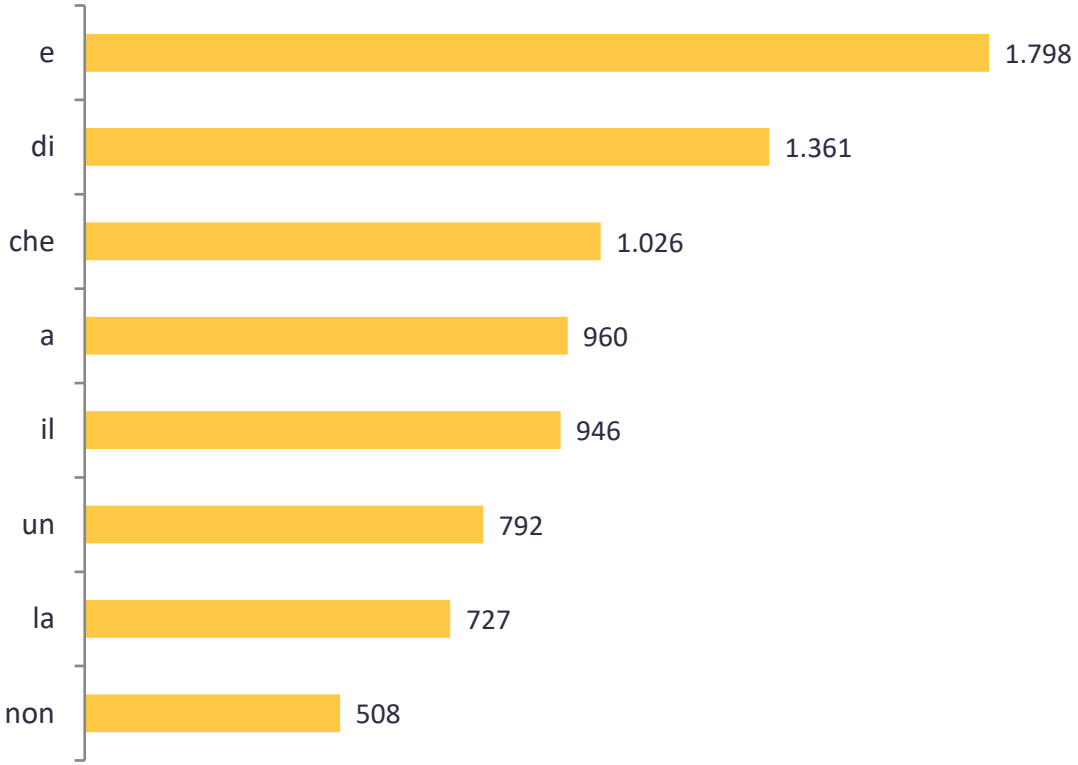
tipi
parole diverse

Ogni scelta conta

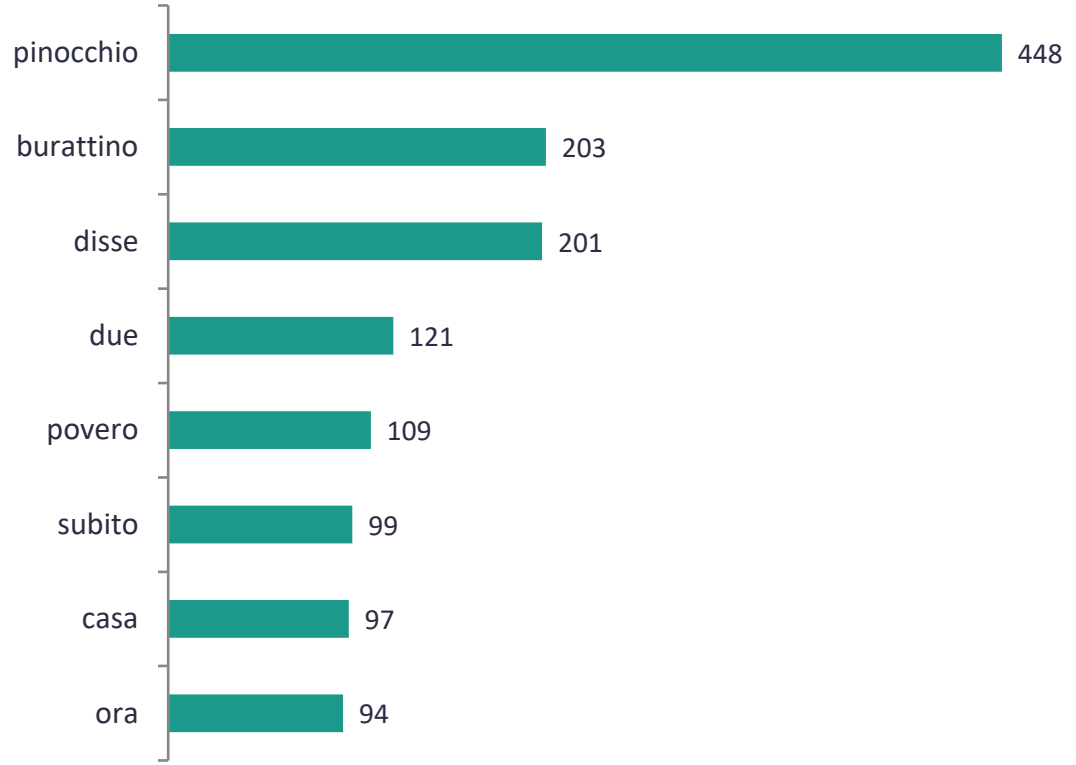
- l'acqua diventa l + acqua
- Pinocchio = pinocchio
- la punteggiatura sparisce

Le parole frequenti dicono lo stile

Tutte le parole: vincono le funzionali

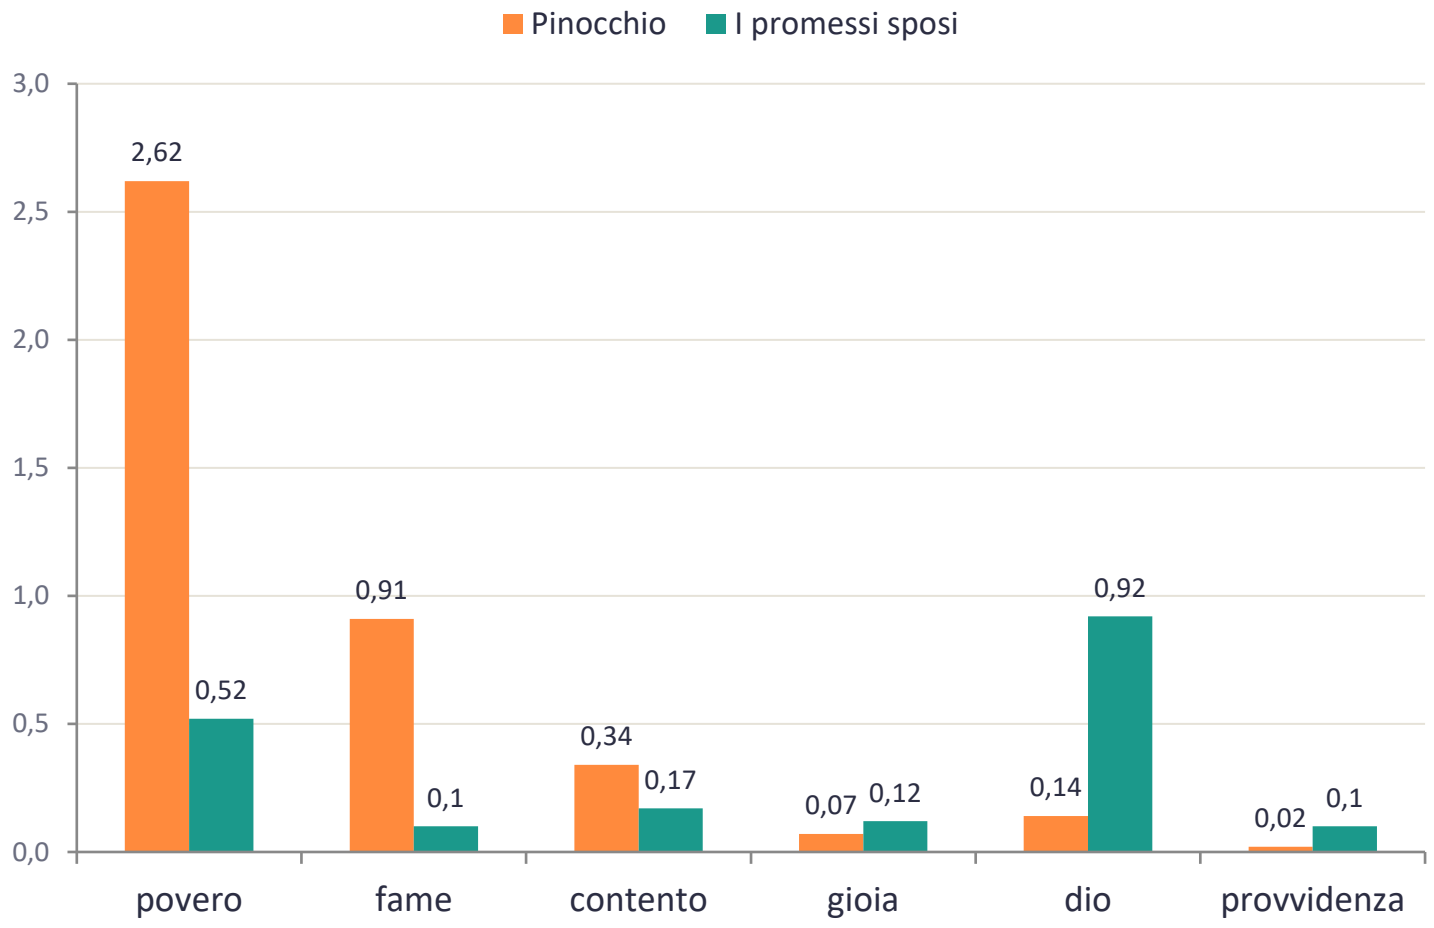


Togliamole



Le stopwords (data/stopwords_it.txt) sono una lista: modificatela!

Confrontare libri diversi ogni 1000 parole



5×

povero: un libro sulla fame e sulla povertà

6×

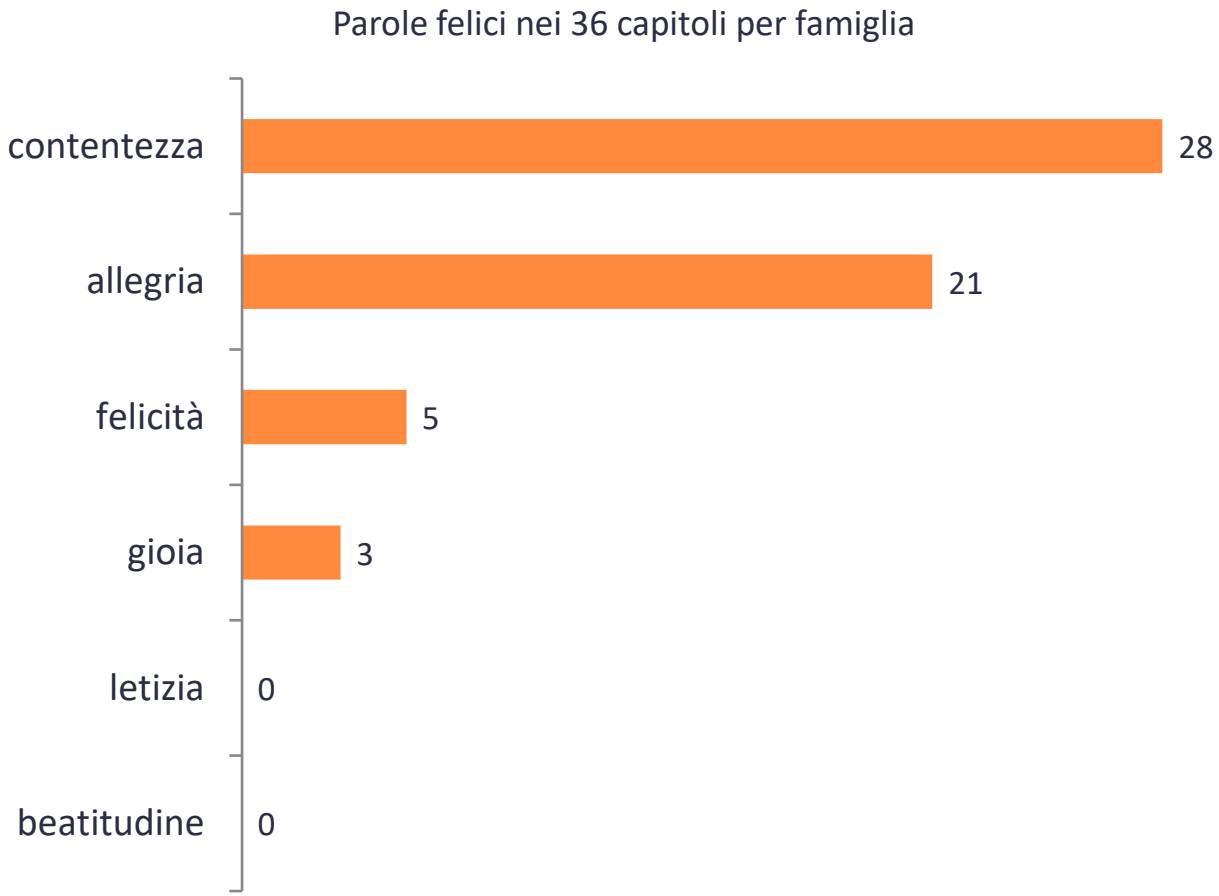
dio nei Promessi sposi, e così la provvidenza

Pinocchio

Un ciclo dentro un ciclo: per ogni capitolo, per ogni parola



In Pinocchio vince la contentezza

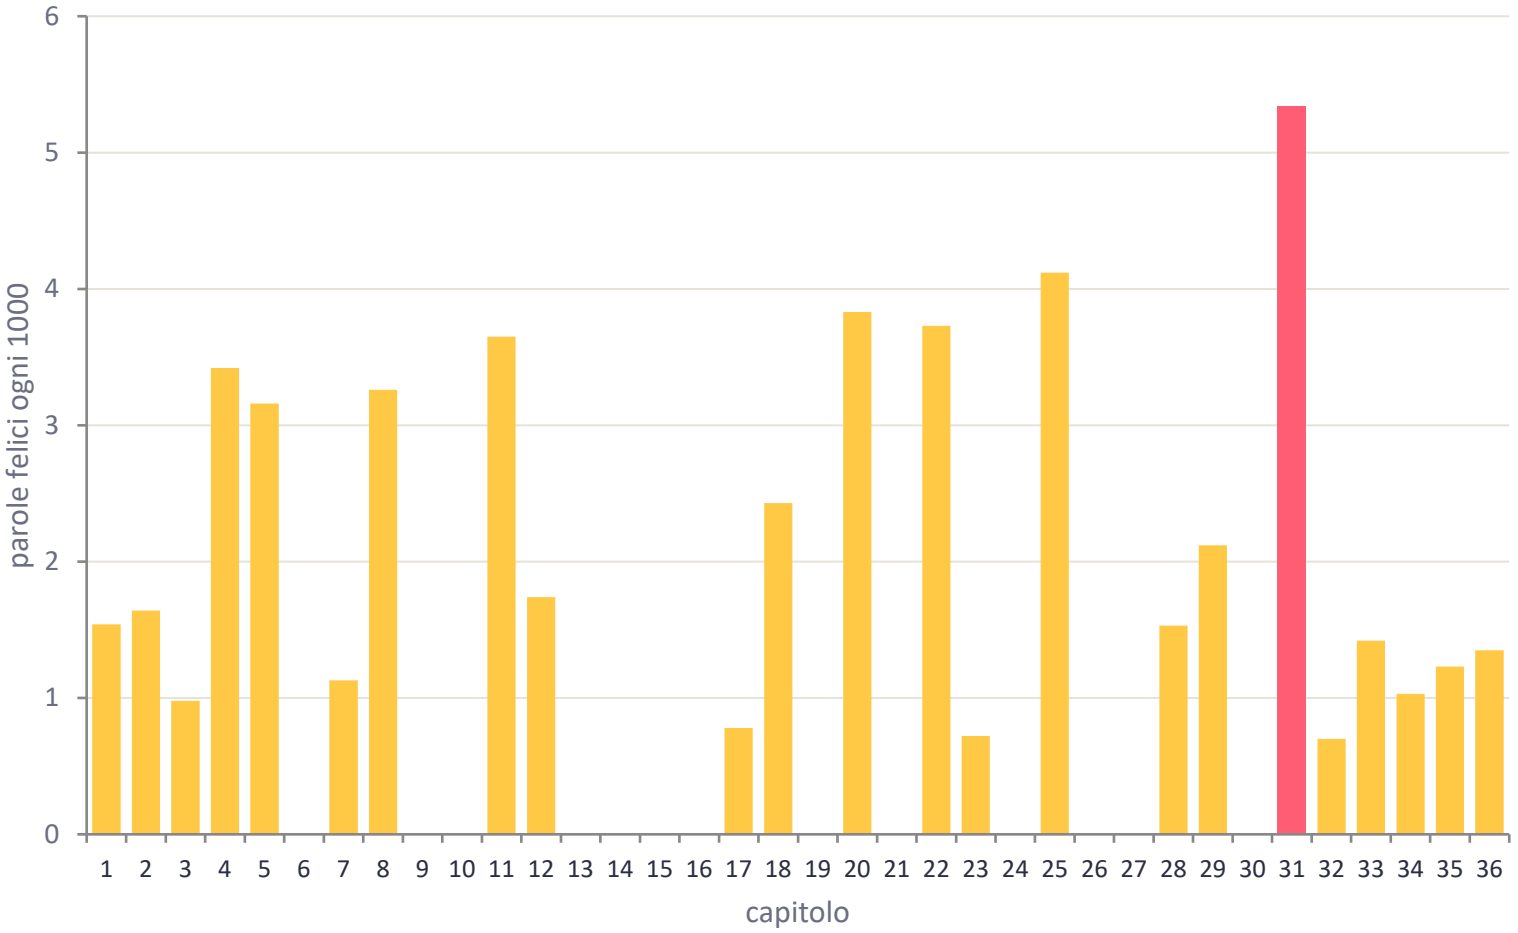


«e dandosi una fregatina di mani per la contentezza, borbottò a mezza voce…»

Maestro Ciliegia, capitolo I

contentezza: la soddisfazione quieta e sufficiente.
letizia e **beatitudine** (registro dantesco): zero.

Il capitolo felice è una trappola



Capitolo XXXI

Paese dei Balocchi e orecchie d’asino

Il contrasto tra la gioia superficiale e il rischio profondo è il meccanismo

Dalla tabella al CSV

capitolo	contentezza	allegria	gioia	parole
1	1	0	0	648
2	1	0	0	609
3	0	1	0	1022
4	2	0	0	585
5	0	1	1	633

Dai testi ai numeri: l'albero



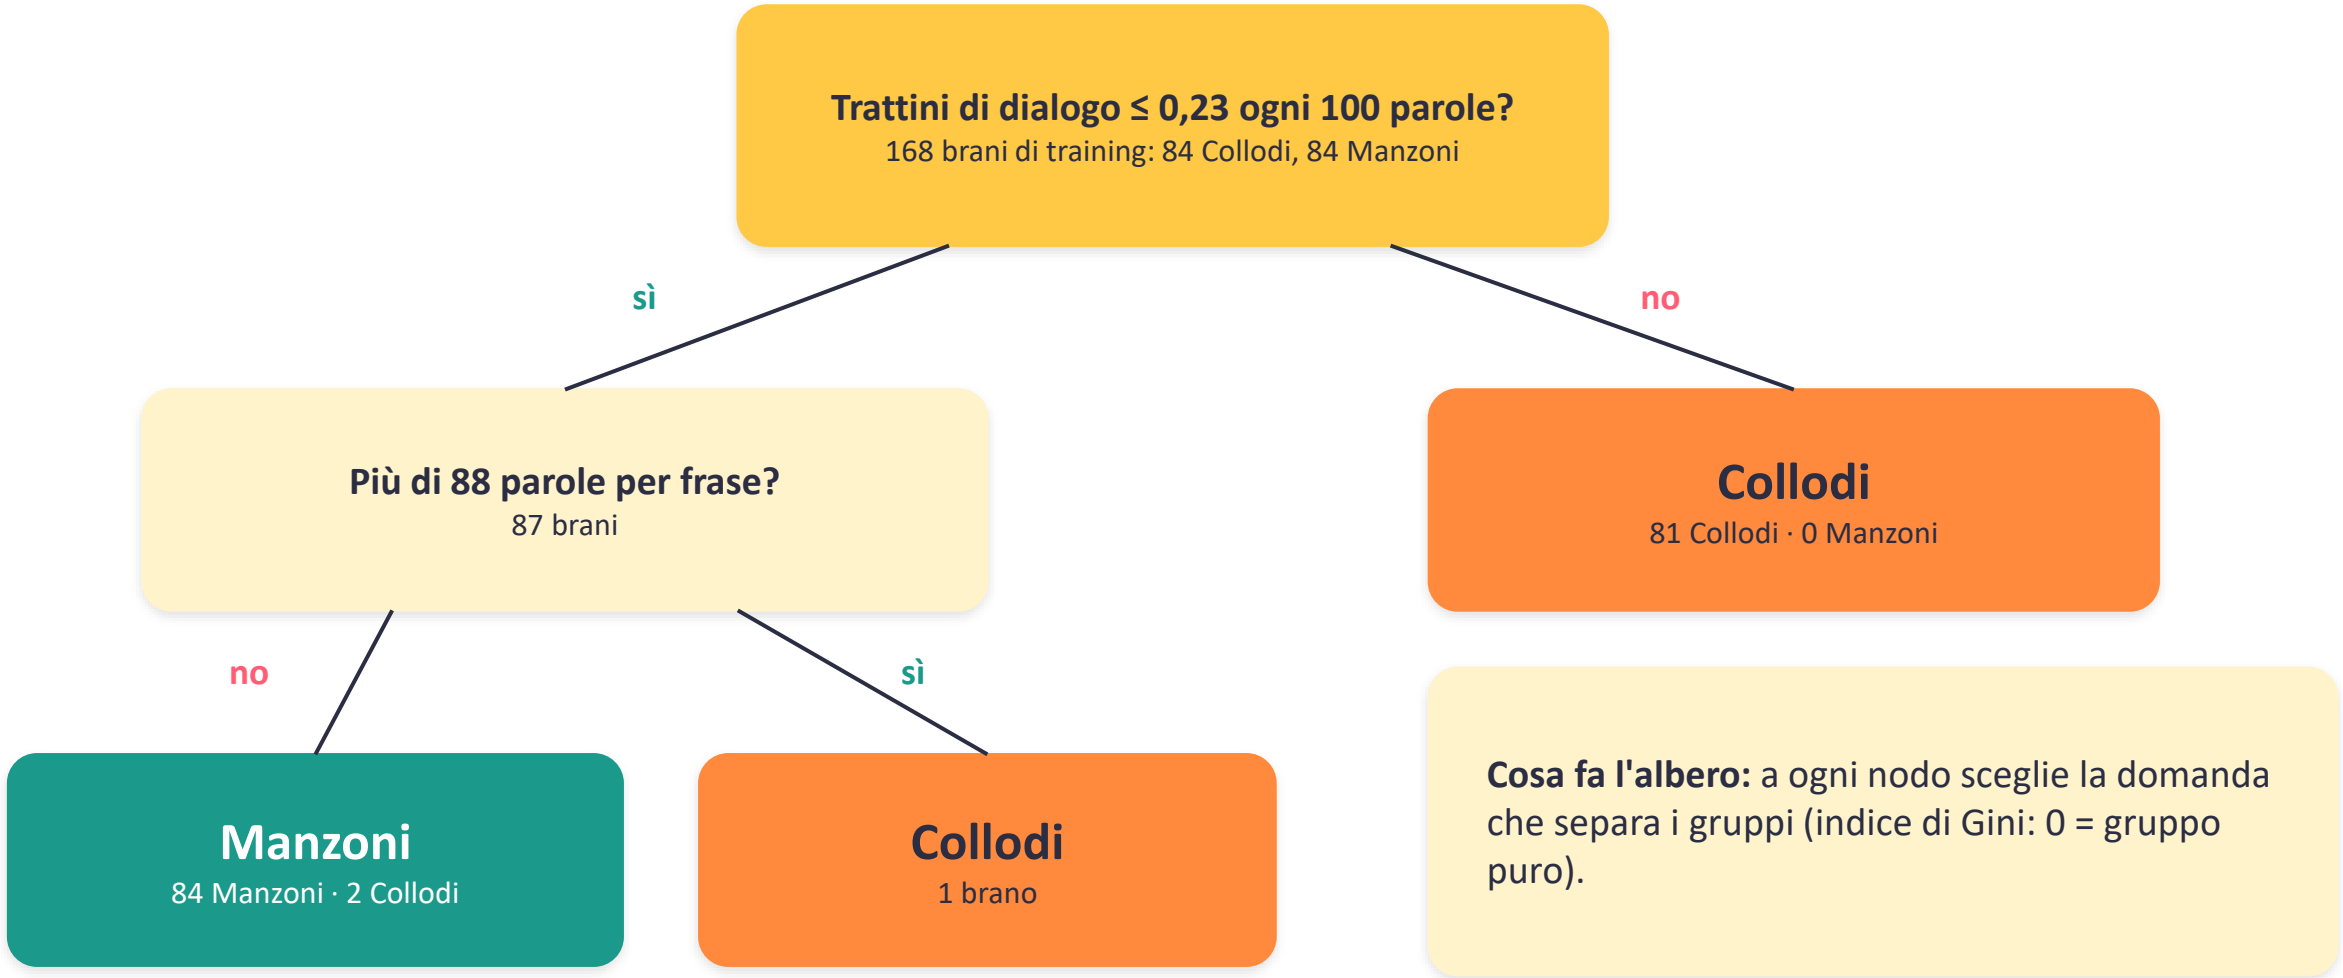
Ogni brano diventa una riga di numeri

autore	parole per frase	trattini ogni 100 parole	; ogni 100 parole	! ogni 100 parole	felici ogni 1000 parole
Collodi	16,66	4,84	0,45	1,70	1,50
Deledda	15,41	3,42	0,94	1,10	1,09
Di Giacomo	14,63	3,19	0,45	1,14	0,52
Manzoni	**26,08**	**0,00**	**1,80**	0,68	1,31
Pirandello	19,79	2,10	0,95	1,18	0,80



Stilometria: scegliamo le misure e la scelta è un'interpretazione.

Un albero è una serie di domande



Cosa fa l'albero: a ogni nodo sceglie la domanda che separa i gruppi (indice di Gini: 0 = gruppo puro).

98,6%

di risposte giuste su 72 brani nuovi (Collodi o Manzoni?)

```
«— Che cosa vuoi? — gridò il burattino.» → Collodi
```

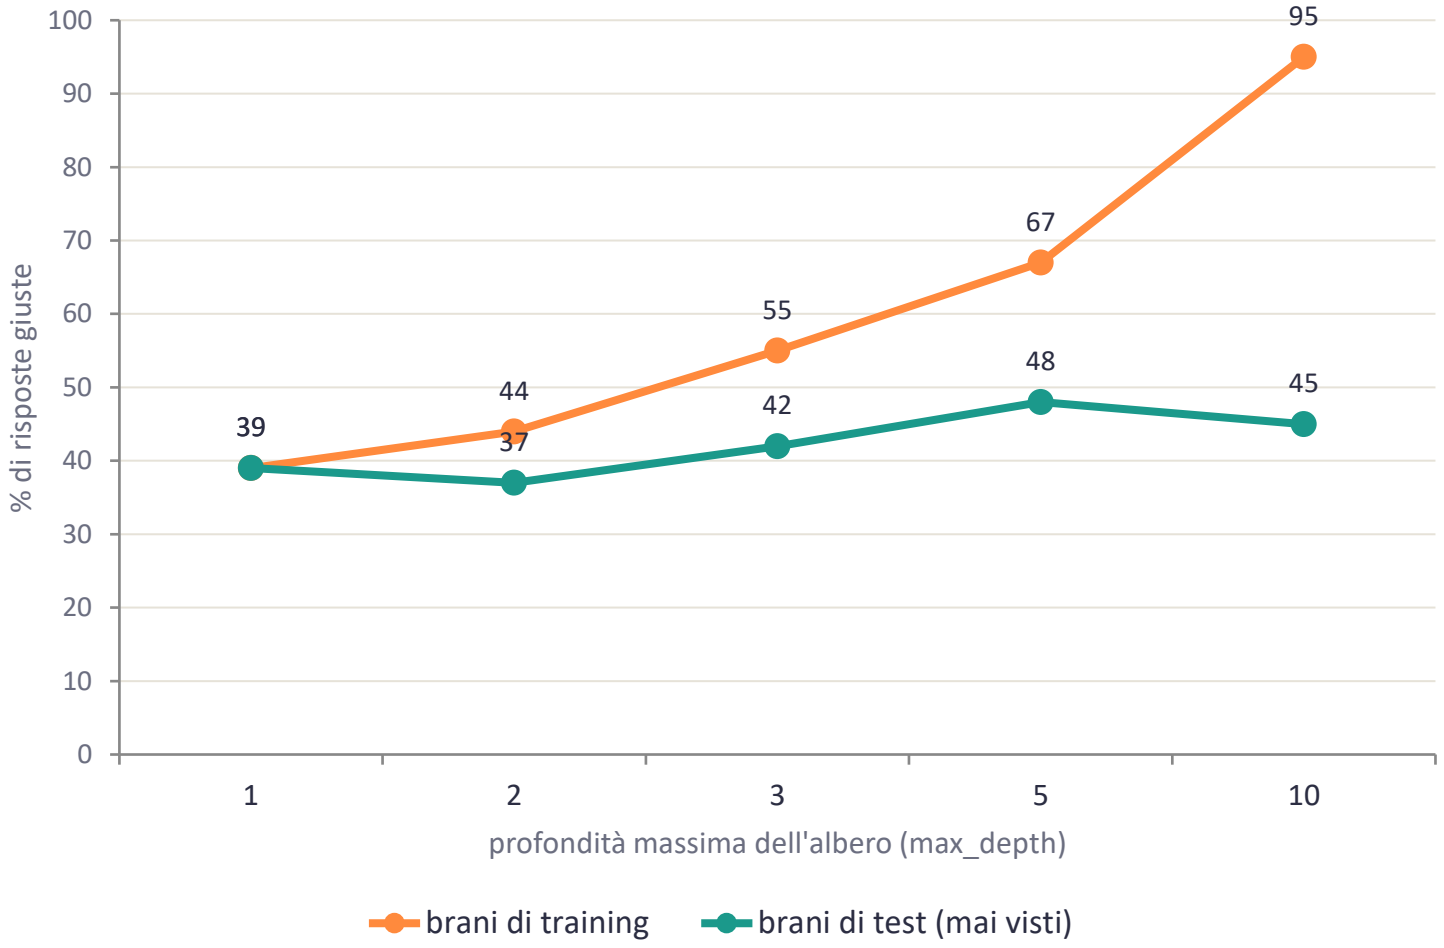


Che cosa ha scoperto
Un fatto filologico vero: in questa edizione Manzoni evita di usare il trattino per i dialoghi.



Perché è fragile
Dipende dall'edizione: con un'altra edizione dei Promessi sposi la regola crolla.

Cinque autori



Overfitting

Con max_depth = 10 l'albero indovina il 95% dei brani che ha visto, ma sbaglia su brani nuovi (a caso: 20%).

Il numero che conta è il test

Concetti

1. Un testo diventa numeri: token, frequenze, caratteristiche
2. Un albero di decisione è come una serie di domande
3. Un risultato può essere giusto per la ragione sbagliata



Laboratorio

1

Le parole di una poesia

Le 10 parole di contenuto più frequenti in A Silvia. Che cosa ci dicono?

2

Un CSV della felicità

Le sei famiglie nelle 40 poesie dei Canti, salvate in risultati/leopardi_felicita.csv.

3

Cinque autori

Un albero su tutti gli autori: accuratezza, feature_importances_, max_depth = 10.

Notebook: lessons/02_dati_e_parole_alberi.ipynb
Soluzioni: solutions/02_dati_e_parole_alberi_soluzioni.ipynb