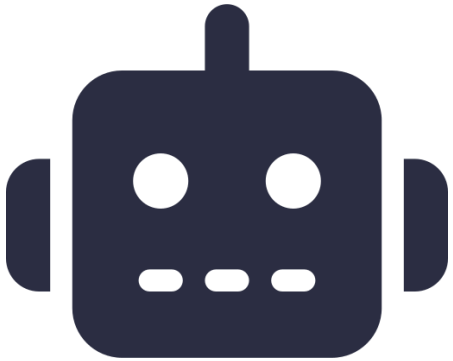
Machine Learning for the Humanities

Support Vector Machines

Lezione 3 · 9 novembre 2026 · Tor Vergata





La domanda dell’apprendimento automatico

Una macchina può scoprire le regole?

Cinque Autori, 600 brani di 200 parole



Regole o esempi

programmare a regole vs apprendimento supervisionato



Bag of words e TF-IDF

il testo come vettore di parole



SVM

il confine con il margine massimo



Scikit-learn

addestrare, valutare e usare un classificatore



Guardare

quali parole ha imparato a usare?

Recap: Due modi di insegnare a una macchina



Scrivere le regole

- Trasparenti
- Faticose

`«se compare Renzo, è Manzoni»`



Imparare dagli esempi

- diamo brani con etichette
- l'algoritmo cerca le regola
- migliora con migliori esempi

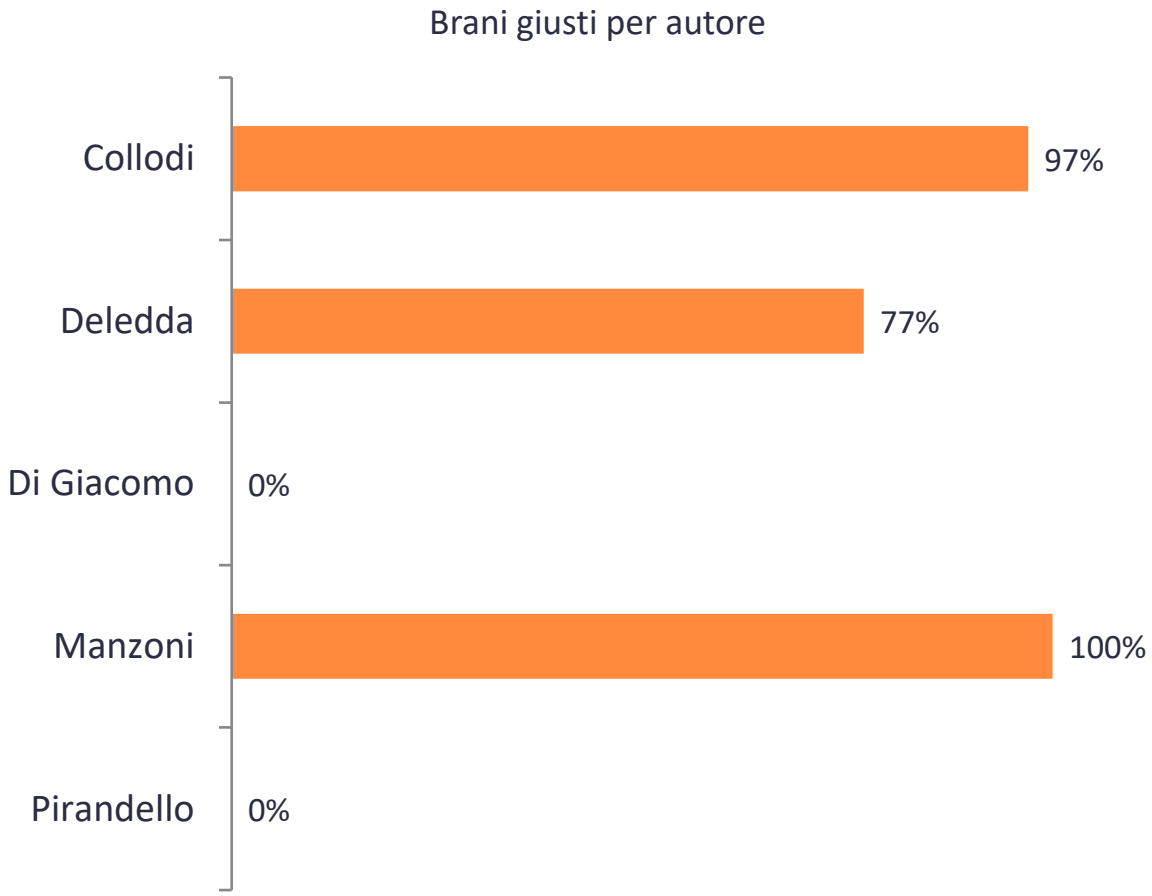
`450 brani → autore`

Le regole a mano funzionano a metà

```
if "pinocchio" in t: return "Collodi"
if "renzo" in t:     return "Manzoni"
if "—" not in t:     return "Manzoni"
return "Deledda"   # ripiego
```

55%

82 brani giusti su 150 mai visti



Il testo: un sacco di parole

Ogni brano deve diventare una riga di numeri



Bag of words: contare ogni parola

frase 1 «Che gioia il sabato del villaggio»

frase 2 «Il sabato porta gioia e poi noia»

frase 3 «La noia del lunedì»

	che	del	gioia	il	la	lunedì	noia	poi	porta	sabato	villaggio
frase 1	**1**	**1**	**1**	**1**	0	0	0	0	0	**1**	**1**
frase 2	0	0	**1**	**1**	0	0	**1**	**1**	**1**	**1**	0
frase 3	0	**1**	0	0	**1**	**1**	**1**	0	0	0	0



L'ordine delle parole scompare: «il cane morde l'uomo» e «l'uomo morde il cane» hanno lo stesso vettore: è un sacco di parole

TF-IDF

	che	del	gioia	il	la	lunedì	noia	poi	porta	sabato	villaggio
frase 1	0,48	0,37	0,37	0,37	0	0	0	0	0	0,37	0,48
frase 2	0	0	0,37	0,37	0	0	0,37	0,48	0,48	0,37	0
frase 3	0	0,43	0	0	0,56	0,56	0,43	0	0	0	0

TF **term frequency**

quanto la parola è frequente in questo testo

IDF **inverse document frequency**

quanto è rara negli altri testi

→ **il risultato**

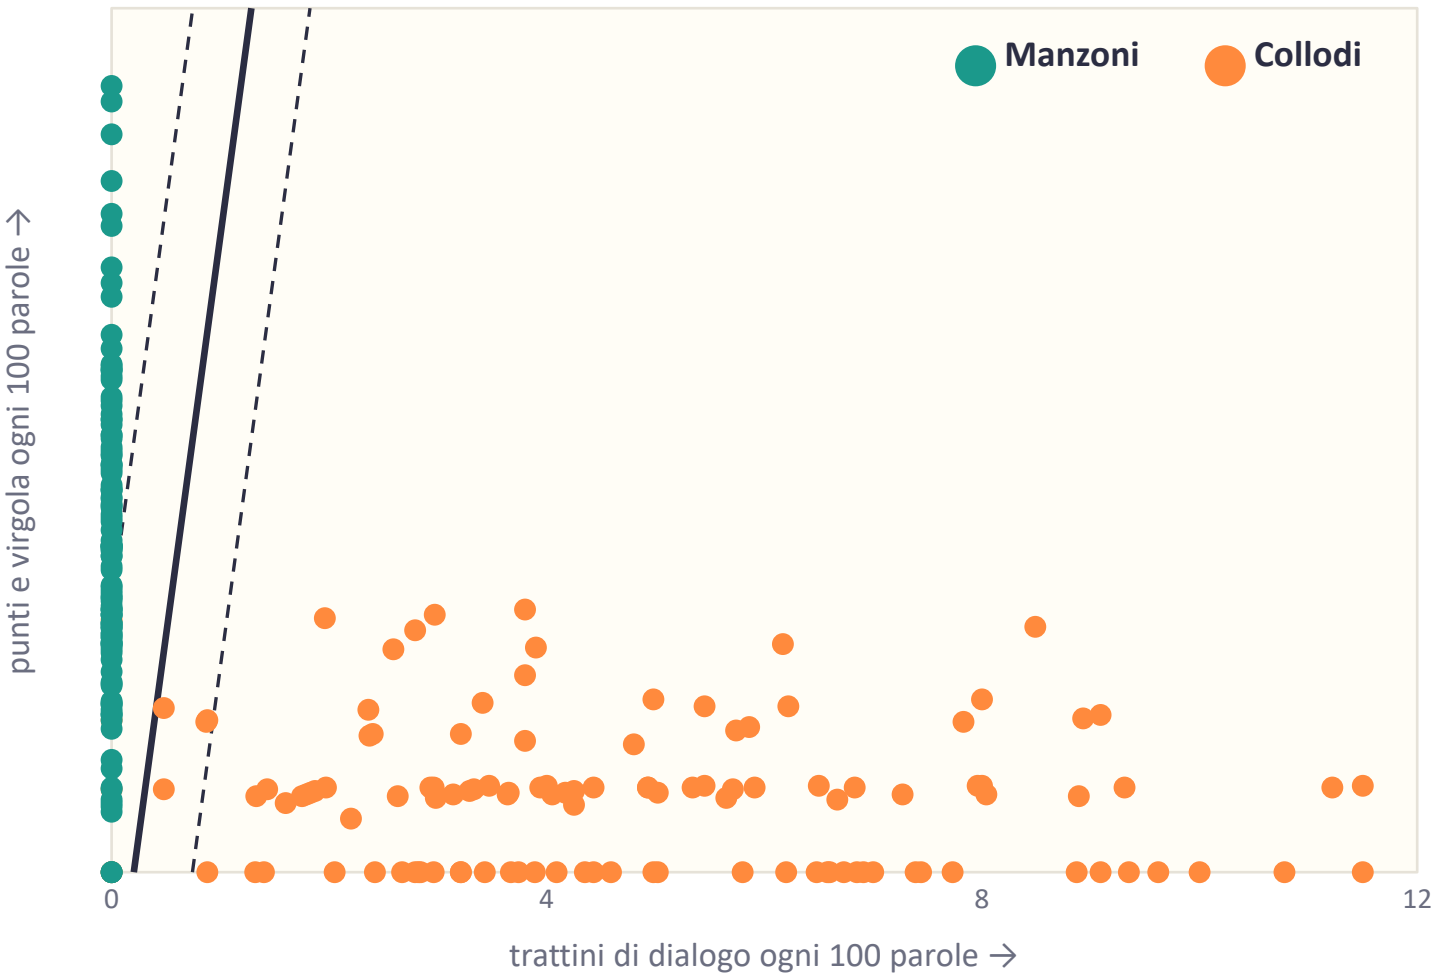
pesano le parole tipiche di un testo (in verde)

La Support Vector Machine

Cercare il confine con il margine massimo



Un confine lontano



Il confine
la linea continua separa i due autori.

Il margine
il tratteggio: la SVM vuole il confine con la distanza massima da ogni gruppo

I vettori di supporto
i brani sul bordo del margine decidono il confine.

La pipeline in scikit-learn



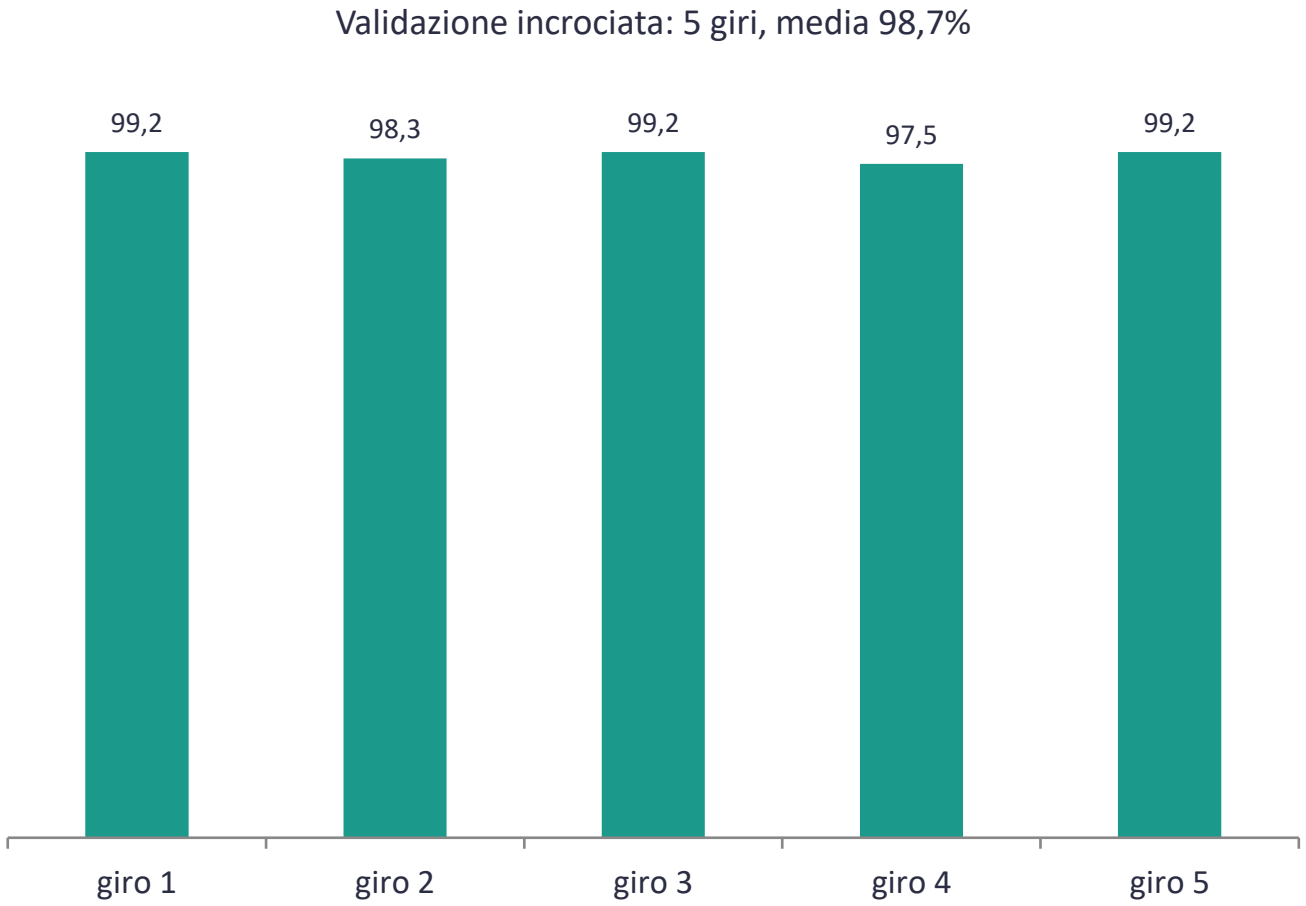

```
modello = make_pipeline(TfidfVectorizer(), LinearSVC())
modello.fit(X_train, y_train)
modello.score(X_test, y_test)        # brani MAI visti
modello.predict(["Il burattino, tutto contento..."])
```

Risultato

100%

dei 150 brani di test all'autore giusto (a caso: 20%, regole a mano: 55%)

Con sequenze di caratteri **98,7%**: desinenze, grafie e punteggiatura funzionano come le parole.



Che cosa ha imparato? Le parole pesanti

Collodi	Deledda	Di Giacomo	Manzoni	Pirandello
pinocchio	**costantino**	la	**renzo**	**mimma**
burattino	**giovanna**	si	**lucia**	lei
geppetto	**zia**	**piccino**	de	**bax**
fata	egli	**vedova**	che	**crispucci**
ragazzi	ed	le	**don**	**naldi**
babbo	**giacobbe**	**tore**	**padre**	bestia
assassini	**brontu**	mormorò	parte	su



In arancione personaggi e ruoli: il modello "bara" un po'. Il resto sono grafie e lingua (que, de', ed, egli, mormorò)

Tocca a voi: sei tu la SVM

Inquadrate il QR code con il telefono

1. **Il confine**
   Separate l'Inferno dal Paradiso con una linea

2. **Le parole pesanti**
   «pinocchio» o «felice»?

3. **Metti alla prova la SVM**
   Scrivete una frase



Inquadrami!

yuri-bizzoni.github.io/yuribizzoni/ml-humanities/gioco-svm

Proviamo con frasi nuove

«Il burattino, tutto contento, si mise a ballare per la stanza.» → Collodi

«Quel ramo del lago, che volge a mezzogiorno, era tutto quieto; e la gente tornava a casa.» → Pirandello

«La felicità? Una maschera, signori miei, che ci mettiamo per non vederci.» → Pirandello

«Nel cortile, sotto la luna, la donna aspettava, e il vento portava odore di lentischio.» → Di Giacomo

La seconda fa il verso all'incipit di Manzoni: ma il modello conosce i 90 brani di Manzoni che ha visto

Troppo bello per essere vero?



Ogni autore nei nostri dati ha un solo libro

Che cosa ha imparato?

La macchina potrebbe imparare a riconoscere il libro (“Pinocchio”)

Come scoprirlo?

Mettere alla prova il modello su un altro libro dello stesso autore.

SV in ricerca vera

https://aclanthology.org/2023.wnu-1.5.pdf



Filosofia spicciola

- Parallelo con sistemi biologici: un mondo di premi e punizioni
- Se il modello indovina la risposta giusta, ottiene un ”premio” (reward function)

Filosofia spicciola

- Un algoritmo di apprendimento automatico cerca di creare un modello ”abbastanza buono” da permettere previsioni giuste con alta sicurezza su elementi nuovi
- Animali, persone e così via fanno una cosa simile
- Non abbiamo (bisogno di) una teoria perfetta della vita prima di vivere
- Abbiamo solo bisogno di saper scegliere il prossimo passo

$$P\big(\mathrm{error}(h) \leq \varepsilon\big) \geq 1 - \delta$$

- h è il modello (p.e. cosa dà piacere, cosa possiamo mangiare, come vogliamo vivere…)
- Epsilon è quanto siamo disposti a sbagliare
- Delta è la probabilità che il modello non riesca a superare una certa soglia di accuratezza

Filosofia spicciola

- Ma la vita di un sistema biologico assomiglia forse di più a un apprendimento non supervisionato
- Accumuliamo osservazioni: incontri, eventi, esperienze, momenti etc
- Ogni evento contiene molti dati da esplorare: exploratory data analysis
- I patterns che scopriamo potrebbero essere nuovi o inattesi
- Esperienze che sembrano scollegate potrebbero avere un segreto elemento in comune
- Forse quello che pensavamo ci avrebbe fatti contenti ci rende infelici
- Nella vita continuiamo a cercare di scoprire strutture latenti sotto le nostre esperienze

Lessico e concetti

Prossima lezione, 11 novembre:

- Un'accuratezza del 95% è buona?
- Unsupervised learning

1. TF-IDF
2. Dagli esempi una SVM con TF-IDF arriva al 100%
3. Il modello impara parole: guardate i pesi
4. Diffidare dei numeri perfetti

Laboratorio

1

Mettere alla prova il modello

Tre frasi «alla maniera di» e un messaggio WhatsApp. Che cosa risponde?

2

Lettere in vece di parole

TfidfVectorizer(analyzer="char_wb", ngram_range=(2, 4)). Cambia l'accuratezza?

3

Nomi comuni

Togliete i nomi dei personaggi con stop_words. Cambia l'accuratezza?

Notebook: lessons/03_imparare_dagli_esempi_svm.ipynb
Soluzioni: solutions/03_imparare_dagli_esempi_svm_soluzioni.ipynb