Misurare il risultato





La domanda guida

Un'accuratezza del 95% è buona?



Baseline

il punteggio della strategia stupida



Matrice di confusione



Precision e recall



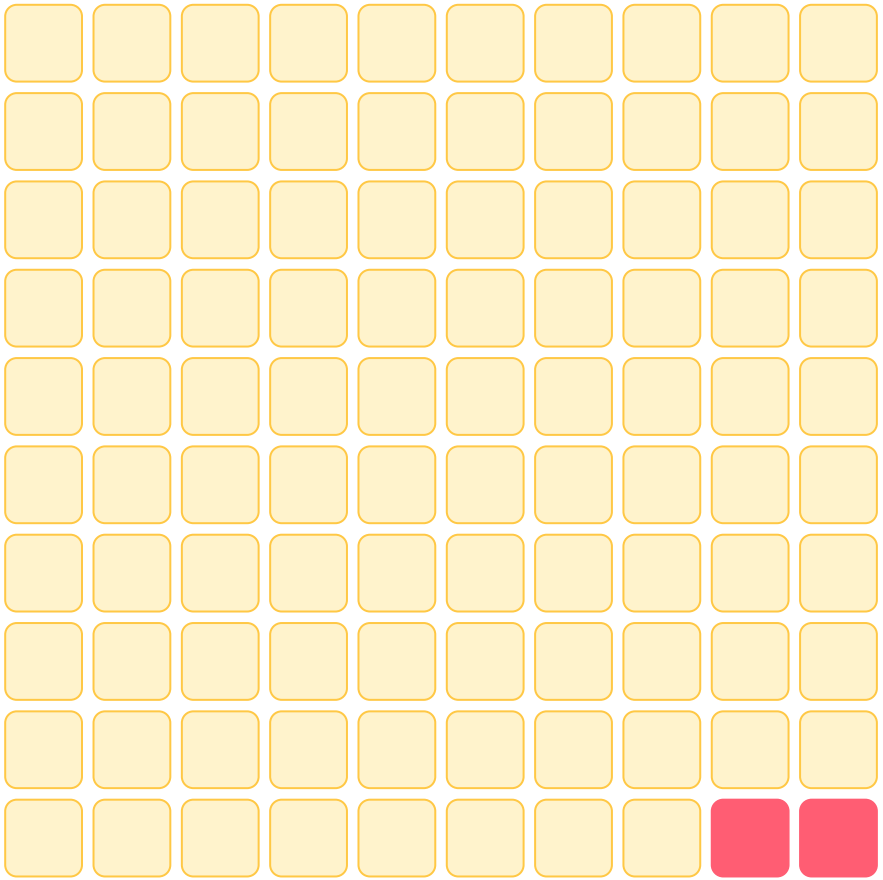
Classi



Unsupervised

cercare struttura

Il caso: un rilevatore di frasi felici



29.040 frasi da tutti i testi del corso; **630** contengono una parola felice: il **2,2%**. Ogni quadratino è l'1%.

Il compito: indovinare dal contesto

«Il burattino, tutto […], prese a ballare per la stanza.»

Anche l'etichetta è una scelta
Una frase è "felice" se contiene una forma delle 35 forme (felice, lieta, gioia, contento…). Ma «non era felice» conta come felice, e «sorrise» come non-felice.

La baseline è il punteggio del pigro

Strategia: rispondere «non felice»

97,8%

di accuratezza

0 su 157

frasi felici trovate

Se una classe è rara, il numero da battere è superiore al 50%.

Il nostro modello è pigro

Il modello pigro

DummyClassifier

accuratezza **97,8%**

frasi felici trovate **0 su 157**

Il nostro modello

TF-IDF + regressione logistica

accuratezza **97,8%**

frasi felici trovate **0 su 157**

Matrice di confusione, Precision e Recall



La matrice di confusione



Un modello migliore

Trova 37 frasi felici su 157.

In cambio dà 377 falsi allarmi.

L'accuratezza scende al 93,2%, ma ora il modello è in effetti migliore.

Precision e recall: l'archivio

Cercate in un archivio le lettere che parlano di felicità.

Precision

Di cosa ho trovato, quanto è giusto?

`VP / (VP + FP)`

0,09

Recall

Di cosa dovevo trovare, quante cose ho trovato?

`VP / (VP + FN)`

0,24

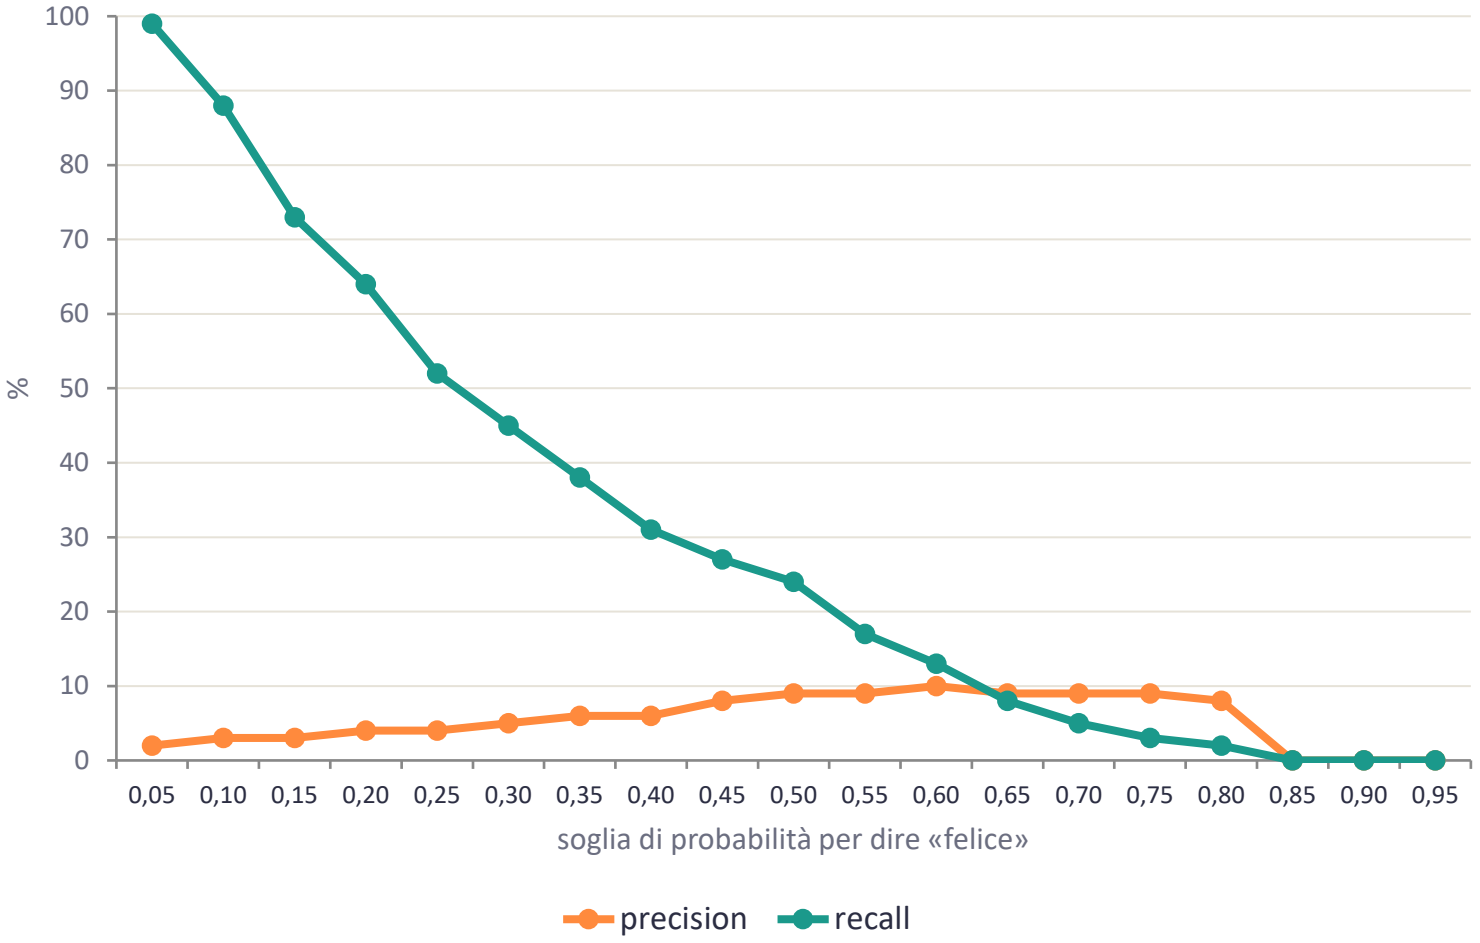
F1

Una media

`2·P·R / (P + R)`

0,13

Spostare la soglia: trovare tutto o sbagliare poco



Soglia bassa
trova tutte le frasi felici ma è pieno di falsi allarmi.

Soglia alta
pochi allarmi, nessuna frase giusta.

La precision resta bassa

Una storia vera: il 100% che non c'era



Prima versione del notebook: maschera ___ invece di [...]

Risultato

100%

di accuratezza sulle frasi di test

Il trucco

_____

per il vettorizzatore era una parola, e compariva solo nelle frasi felici

Il nome

data leakage

fuga di informazione: il modello «sbircia» la risposta

Frasi singole: scambi

vero ↓ previsto →

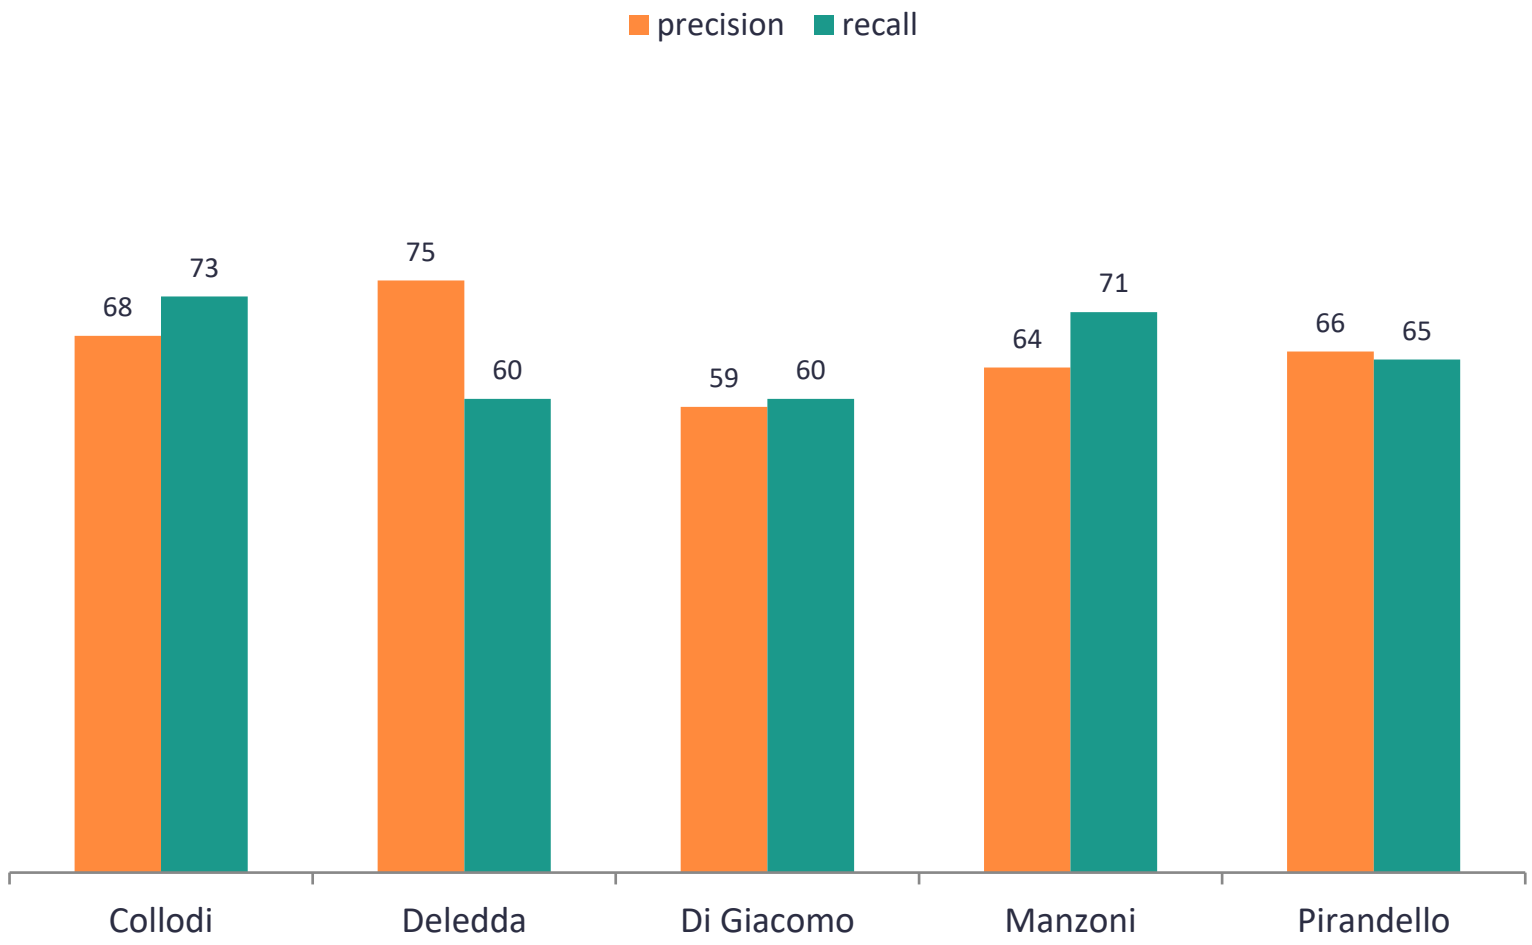
	Collodi	Deledda	Di Giacomo	Manzoni	Pirandello
Collodi	**110**	9	8	14	9
Deledda	12	**90**	**27**	14	7
Di Giacomo	15	6	**90**	15	**24**
Manzoni	15	4	14	**107**	10
Pirandello	10	11	14	18	**97**

65,9%

di frasi attribuite bene (a caso: 20%; con brani di 200 parole era quasi il 100%)

La confusione più forte: Deledda scambiata per Di Giacomo (27 volte) e Di Giacomo per Pirandello (24). Un dato da leggere da filologi, non solo da contare.

Precision e recall, autore per autore



Collodi e Manzoni si riconoscono meglio (personaggi, registro, grafia ottocentesca).

Di Giacomo ha la precision più bassa: molte frasi altrui finiscono a lui.

Da una ricerca vera

	Positive Class Ratio	ROC-AUC	Average Precision	F1
Work mentioned on author's Wikipedia	0.5379	0.795755	0.782712	0.770992
Published by Reclam	0.0778	0.744019	0.149542	0.207533
Author mentioned in literary history	0.6515	0.566408	0.709993	0.615459
Combined	0.1882	0.673942	0.313810	0.381404

Table 1. Classification results reception metric

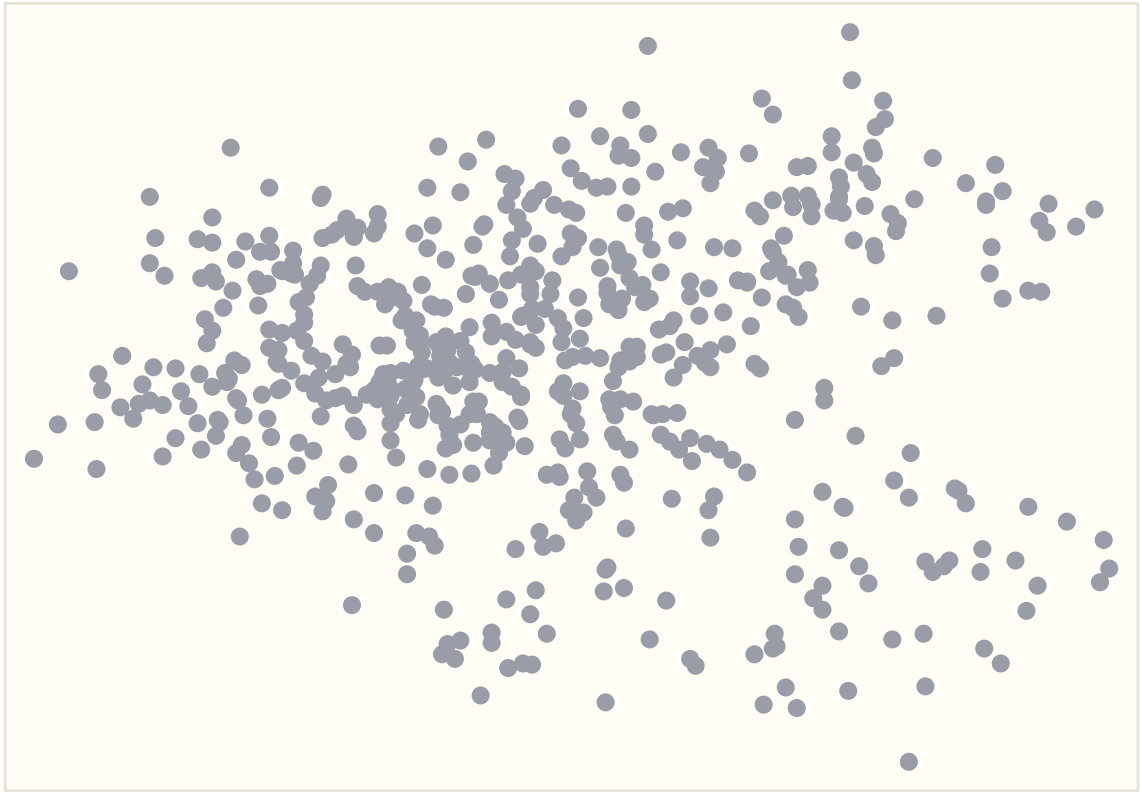
Quanto è buono questo classificatore?
Come potremmo migliorarlo?

Unsupervised



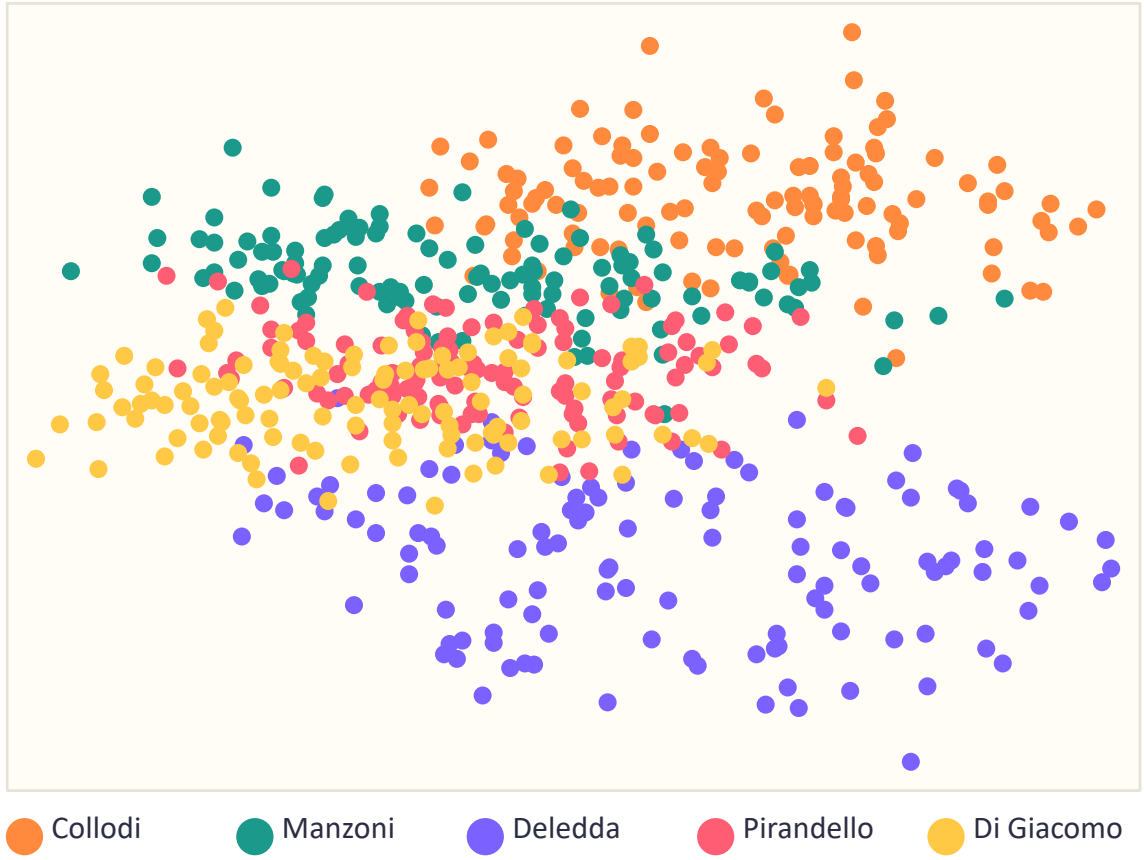
Senza etichette: il non supervisionato

Ciò che vede il modello



600 brani, PCA da 2.000 colonne TF-IDF a 2

Gli stessi punti, colorati dopo per autore



Laboratorio: tocca a voi

1

A mano

Un rilevatore di ironia «al 95%»: 1000 frasi, 50 ironiche, ne segnala 30 (20 giuste). Calcolate precision, recall, F1. È buono?

2

Leggere gli errori

Mostrate 8 falsi positivi del modello bilanciato. Sono davvero frasi «non felici»?

3

L'autore più difficile

Baseline most_frequent e stratified, recall per autore. Chi è più difficile, e perché?

Notebook: lessons/04_misurare_il_risultato.ipynb · Soluzioni: solutions/04_misurare_il_risultato_soluzioni.ipynb

Da portare a casa

Prossima lezione, 12 novembre: l'AI come assistente, e il k-means

1. Confrontate sempre con una baseline
2. Con classi rare l'accuratezza inganna: guardate precision e recall
3. La matrice di confusione dice chi viene scambiato con chi
4. Un risultato troppo bello? Cercate la fuga di informazione